

Analiza oraz wizualizacja danych meteorologicznych dla wybranych ośrodków narciarskich



Michał Bugno Antek Piechnik
prowadzący: **dr inż. Robert Marcjan**

29 września 2009

Spis treści

1 Wstęp	4
1.1 Wizja	4
1.2 Ocena ryzyka	4
2 Ogólna struktura systemu	4
2.1 Baza danych	4
2.2 Technologia	4
2.3 Crawler	5
2.4 Wizualizacja	5
2.5 Entity Relationship Diagram	6
3 Aplikacja Django	6
3.1 Modele	6
3.2 Metody	7
3.2.1 Wybranie obiektu z bazy	7
3.2.2 Państwo, w którym leży resort	7
3.2.3 Najbliższe resorty	7
3.3 SQL	8
3.3.1 Stworzenie tabel	8
3.3.2 Spatial queries	9
3.4 Integracja z GoogleMaps API	10
3.4.1 Granice Austrii	10
3.5 Fikstury	11
3.6 Wizualizacja danych	11
3.7 Metody Oracle Spatial	11
3.7.1 SDO_UTIL.TO_WKTGEOMETRY	11
3.7.2 SDO_GEOM.SDO_BUFFER	11
3.7.3 SDO_GEOM.SDO_CONVEXHULL	12
3.7.4 MDSYS.SDO_GEOMETRY	12
3.7.5 SDO_GEOM.SDO_ELEM_INFO_ARRAY	12
3.7.6 SDO_ORDINATE_ARRAY	12
3.8 Konkretnie zadania wizualizujące	12
3.8.1 Wizualizacja izoterm	12
4 Wyniki wizualizacji izoterm.	14

5	Crawler	18
5.1	Extract	18
6	Raport z prac	18
6.1	Crawler	18
6.2	Import danych	19
6.3	Analiza danych	19
6.4	Wizualizacja danych	19
6.5	Dodatkowe	20
7	Linki	20

1 Wstęp

1.1 Wizja

Głównym zadaniem projektu jest poznanie struktury danych typu GIS (geographical information system), jak również analiza oraz wykorzystanie tego typu danych w wizualizacji danych meteorologicznych. System docelowo ma za zadanie przedstawienie sytuacji meteorologicznej na podstawie danych zbieranych na bieżąco jak również danych historycznych zgromadzonych poprzednio. System ma również mieć możliwość udostępniania danych/wizualizacji historycznych na życzenie użytkownika. Do celów badania wydajności systemu wykorzystywane będą dane z przynajmniej dwóch źródeł informacji meteorologicznej, podczas gdy system ma domyślnie obsługiwać 4-5 stacji narciarskich (po kilka punktów na każdą stację).

1.2 Ocena ryzyka

Technologia Django (w konsekwencji również Python) daje dobre perspektywy rozwoju: Python jest językiem bogatym w biblioteki (m.in. do Oracle) i jako język dynamiczny daje możliwość łatwego rozszerzania aplikacji. Dobrze rokuje także projekt GeoDjango (<http://geodjango.org/>) w związku z czym można sądzić, że nie napotkamy na większe problemy implementacyjne (związane z technologią).

2 Ogólna struktura systemu

2.1 Baza danych

Wybraną bazą danych jest Oracle. Wyboru dokonaliśmy głównie ze względu na możliwość dokładnego poznania tego produktu w ramach projektu jak również ze względu na obszerne wsparcie dla danych GIS - Oracle Spatial.

2.2 Technologia

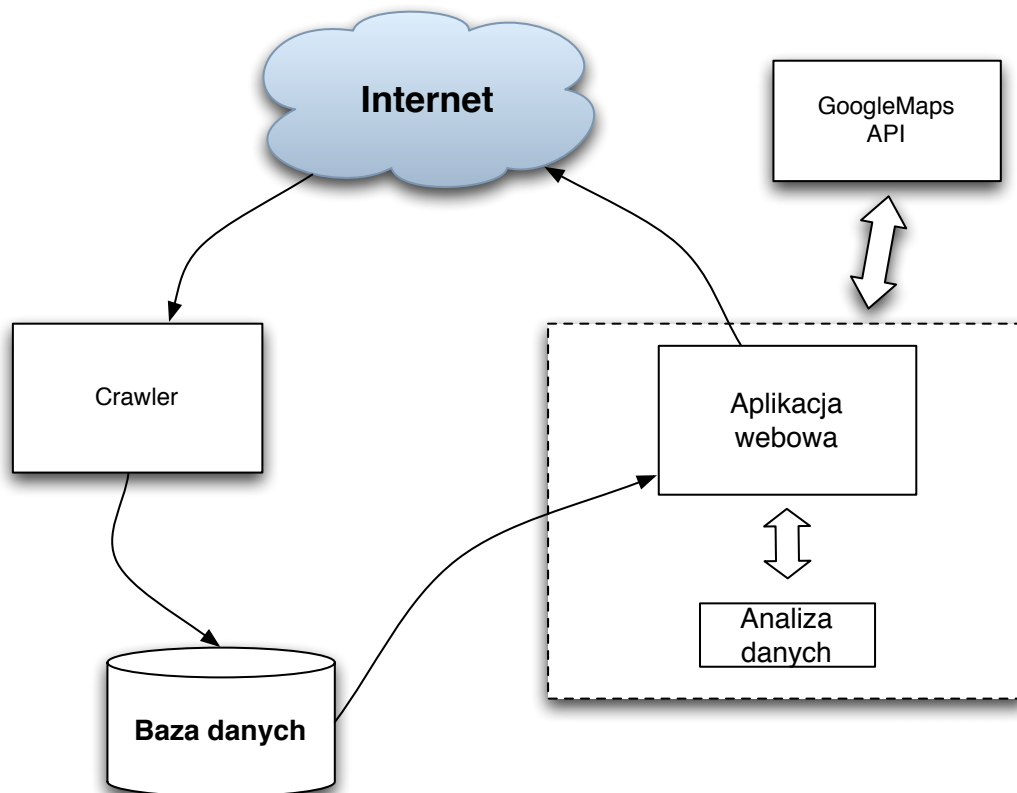
System jest tworzony w technologii Python Django – posiada ona wsparcie dla baz Oracle (w tym Spatial) oraz jest prosta i przejrzysta zapewniając bardziej elastyczny rozwój.

2.3 Crawler

Aplikacja jest w rzeczywistości skryptem mającym na celu pobranie odpowiednich danych z wcześniej przygotowanych źródeł (stron internetowych udostępniających informacje meteorologiczne dla konkretnych ośrodków). Będzie on miał również możliwość aktualizowania bazy danych o pobrane informacje, po uprzednich skonwertowaniu ich do odpowiedniego formatu.

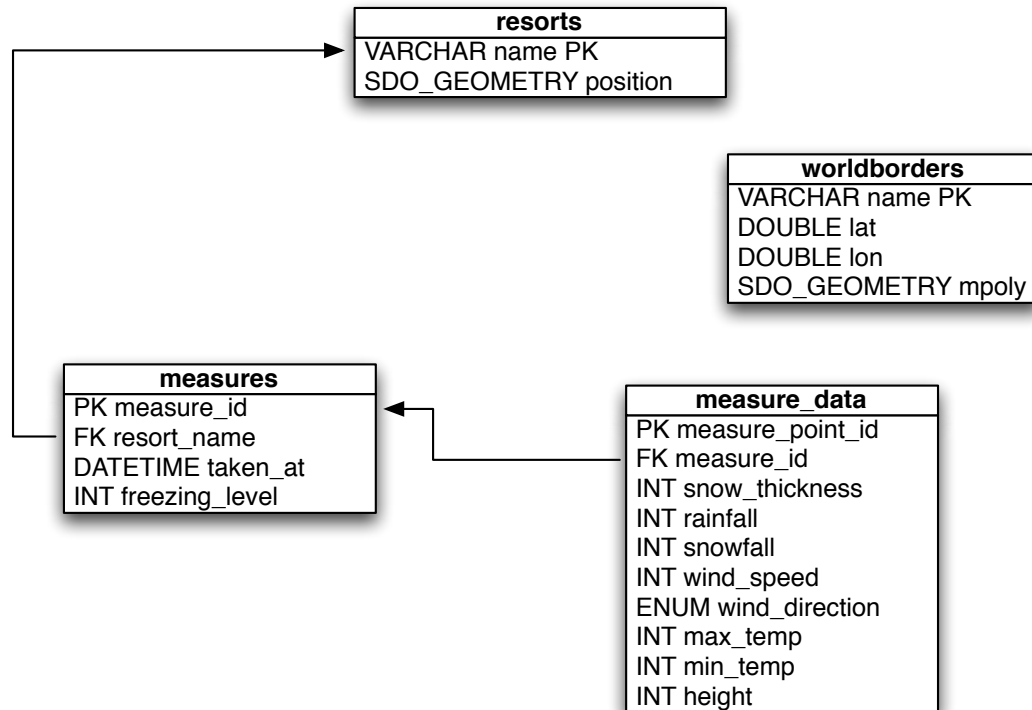
2.4 Wizualizacja

Wizualizacja zostanie utworzona w oparciu o dane wygenerowane przez kontroler analizy danych oraz o API systemu Google Maps który pozwoli na estetyczną wizualizację osiągniętych wyników analizy.



2.5 Entity Relationship Diagram

Poniższy model danych nie jest dokładny, to znaczy tabele **resorts** oraz **worldborders** są już stworzone natomiast pomiary zostaną dodane dopiero po stworzeniu crawlera w związku z czym model może nie wyglądać tak samo.



3 Aplikacja Django

3.1 Modele

Wszystkie modele zawierają pole `objects` typu `models.GeoManager` który odpowiada za wspieranie zapytań Spacialowych. Zdefiniowane w aplikacji modele to:

WorldBorders odpowiada za przechowywanie granic państw. Pola modelu:

name nazwa państwa
lat szerokość geograficzna
lon długość geograficzna

mpoly typ `SDO_GEOMETRY` przechowujący `MultiPolygon` który definiuje granice państwa

Resorts przechowuje ośrodki dla których posiadamy dane pogodowe. Pola:

name nazwa miasta

position dwuwymiarowa geometria `Point` przechowująca długość i szerokość geograficzną miasta

MeasuresResorts przechowuje dane dotyczące pomiarów w ośrodkach na różnych wysokościach.

resort (FK) klucz obcy do tabeli `Resorts`, przechowuje id resortu którego dotyczy pomiar.

altitude wysokość n.p.m.

Measures przechowuje poszczególne pomiary.

measure_resort (FK) klucz obcy do tabeli `MeasuresResorts`, przechowuje id ktorego konkretny pomiar dotyczy

taken_at typ `Datetime` przechowujący czas pomiaru.

max_temp maksymalna temperatura

min_temp minimalna temperatura

3.2 Metody

3.2.1 Wybranie obiektu z bazy

```
austria = WorldBorders.objects.filter(pk=Austria)[0]
first_resort = Resorts.objects.all()[0]
```

3.2.2 Państwo, w którym leży resort

```
country = first_resort.country()
print country.name # => 'Austria'
```

3.2.3 Najbliższe resorty

```
resorts = first_resort.within_distance(30)
# => resorty w odległości 30km od danego (bez danego)
```

3.3 SQL

3.3.1 Stworzenie tabel

Kluczowy dla projektu jest oczywiście typ `SDO_GEOMETRY` który umożliwia wykonywanie specyficznych zapytań geograficznych. Reszta pól to dodatkowe informacje na temat państwa/miasta.

```
CREATE TABLE "WORLD_WORLDBORDERS" (  
    "NAME" NVARCHAR2(50) NOT NULL PRIMARY KEY,  
    "LAT" DOUBLE PRECISION NOT NULL,  
    "LON" DOUBLE PRECISION NOT NULL,  
    "MPOLY" MDSYS.SDO_GEOMETRY NOT NULL  
);
```

```
CREATE TABLE "WORLD_RESORTS" (  
    "NAME" NVARCHAR2(50) NOT NULL PRIMARY KEY,  
    "POSITION" MDSYS.SDO_GEOMETRY NOT NULL  
);
```

Tabela pomiarów posiada dodatkowo klucz obcy do ośrodków aby pomiar można było zaklasyfikować do danego ośrodka.

```
CREATE TABLE "WORLD_MEASURES" (  
    "ID" NUMBER(11) NOT NULL PRIMARY KEY,  
    "RESORT_ID" NUMBER(11) NOT NULL REFERENCES "WORLD_RESORTS" ("ID")  
        DEFERRABLE INITIALLY DEFERRED,  
    "TEMP" NUMBER(11) NOT NULL,  
    "TAKEN_AT" DATE NOT NULL  
);
```

Ustawienia metryki Aby Oracle wiedział, jak wygląda metryka, należy poinformować go ustalając odpowiednie wartości graniczne oraz dokładność dla kolumn `Spatial`. W tym wypadku informujemy, że kolumna `MPOLY` tabeli `WORLD_WORLDBORDERS` posiada zakres długości od -180 do 180 oraz szerokości od -90 do 90 z dokładnością co 0.05.

```
INSERT INTO USER_SDO_GEOM_METADATA  
    ("TABLE_NAME", "COLUMN_NAME", "DIMINFO", "SRID")  
VALUES (
```



```

'world_worldborders',
'mpoly',
MDSYS.SDO_DIM_ARRAY(
  MDSYS.SDO_DIM_ELEMENT('LONG', -180.0, 180.0, 0.05),
  MDSYS.SDO_DIM_ELEMENT('LAT', -90.0, 90.0, 0.05)
),
4326
);

```

Indeksy Aby zapytania mogły funkcjonować należy stworzyć indeksy na kolumnach spatial. Służy do tego polecenie

```

CREATE INDEX "WORLD_RESORTS_POSITION_ID"
ON "WORLD_RESORTS" ("POSITION")
INDEXTYPE IS MDSYS.SPATIAL_INDEX;

```

Sekwencje Warto wspomnieć, że część tabeli ma klucze główne liczbowe i aby nie przejmować się ich numerowaniem stworzyć należy sekwencje. Do tego celu użyliśmy: CREATE SEQUENCE WORLD_WORLDDBORDERS_SEQ i analogiczne dla pozostałych tabel.

3.3.2 Spatial queries

Ośrodki w pobliżu danego ośrodka

```

SELECT "WORLD_RESORTS"."ID", "WORLD_RESORTS"."NAME",
       SDO_UTIL.TO_WKTGEOMETRY("WORLD_RESORTS"."POSITION")
FROM "WORLD_RESORTS"
WHERE
  (SDO_WITHIN_DISTANCE("WORLD_RESORTS"."POSITION",
    SDO_GEOMETRY(POINT (10.7498 46.96297), 4326),
    \'distance=20000.0\') = \'TRUE\'
  AND NOT ("WORLD_RESORTS"."ID" = 832))

```

SDO_WITHIN_DISTANCE to funkcja sprawdzająca czy geometria z pierwszego argumentu znajduje się w pewnej odległości od geometrii drugiego. Jak widać drugą geometrię tworzymy przedstawiając dane geograficzne ośrodka w postaci Well-Known Text: POINT(10.749, 46.962) pierwsza jest natomiast do tej postaci konwertowana przez funkcję TO_WKTGEOMETRY. Trzeci argument to odległość jako liczba metrów. Cała funkcja zwraca true gdy warunek spełniony.

Państwo, w którym znajduje się ośrodek

```
SELECT "WORLD_WORLDBORDERS"."ID", "WORLD_WORLDBORDERS"."NAME",  
       "WORLD_WORLDBORDERS"."LAT", "WORLD_WORLDBORDERS"."LON",  
       SDO_UTIL.TO_WKTGEOMETRY("WORLD_WORLDBORDERS"."MPOLY")  
FROM "WORLD_WORLDBORDERS"  
WHERE SDO_CONTAINS("WORLD_WORLDBORDERS"."MPOLY",  
                   SDO_GEOMETRY(POINT (10.7498 46.96297), 4326)) = \'TRUE\'
```

W tym wypadku używamy funkcji `SDO_CONTAINS` która zwraca prawdę, gdy druga geometria całkowicie zawiera pierwszą. W naszym przypadku pierwszą geometrią jest wielobok przedstawiający granice państwa w tabeli państw natomiast druga to punkt reprezentujący ośrodek. W ten sposób zwracamy wszystkie państwa których granice obejmują ten punkt (w większości przypadków będzie to jeden rekord).

3.4 Integracja z GoogleMaps API

API GoogleMaps jest w języku JavaScript. Wszystkie funkcje, których używamy są zdefiniowane w widokach znajdujących się w katalogu `world/templates`.

Głównym widokiem jest `layout.html` i on definiuje mapę i podstawowe funkcje wyświetlania resortów. Należy pamiętać, że GoogleMaps działają tylko dla domeny, która została podana przy generowaniu klucza, dlatego jeśli domena będzie inna (aktualnie `http://localhost:8000`) należy **wygenerować nowy klucz** i zmienić widok `world/templates/layout.html`.

3.4.1 Granice Austrii

Granice wyświetlane są przez API KML-owe GoogleMaps. Reprezentację KML granic państwa można łatwo wyciągnąć z bazy danych, jednak API nie pozwala na dynamiczne wyświetlanie plików KML i muszą one być dostępne publicznie w Internecie. Z tego powodu wprowadzona jest redundancja danych: w pliku `world/templates/layout.html` znajduje się linia

```
var kml = new GGeoXml("http://student.agh.edu.pl/msq/austria.kml");
```

która definiuje położenie pliku do wyświetlania. W razie potrzeby taki plik można wygenerować za pomocą następujących poleceń:

```
python manage.py shell  
> from world.models import WorldBorders  
> austria = WorldBorders.objects.filter(pk="Austria")[0]  
> print austria.mpoly.kml
```

3.5 Fikstury

Dane do aplikacji mogą zostać ponownie załadowane do bazy (włącznie z uprzednim jej wyczyszczeniem). W plikach `worldborders.fixtures` i `resorts.fixtures` znajdują się odpowiednie dane w prostym formacie tekstowym. Aby załadować je do bazy należy wykonać następujące polecenia:

```
python manage.py shell
> from world import load
> load.load_fixtures()
> # lub load.load_worldborders()
> # lub load.load_resorts()
```

Metoda `load.load_fixtures()` czyści bazę i tworzy wszystkie fikstury natomiast metody `load.load_worldborders()` i `load.load_resorts()` działają na poszczególnych tabelach.

3.6 Wizualizacja danych

W celu wizualizacji danych ściśle powiązanych z GIS wykorzystaliśmy dostępne w Oracle Spatial metody do pracy na wcześniej utworzonych oraz do tworzenia struktur GIS. Poza tym skorzystaliśmy z modułu PIL (Python Imaging Library) do tworzenia obrazów z otrzymanych danych typu WKT (Well-known text).

3.7 Metody Oracle Spatial

3.7.1 SDO_UTIL.TO_WKTGEOMETRY

Konwertuje zadany obiekt typu `SDO_GEOMETRY` do typu WKT - well-known text. Argumentem jest obiekt typu `SDOGEOMETRY`. Well known text (WKT) pozwala nam na sprawną manipulację otrzymanym polygonem chociażby z poziomu biblioteki wizualizującej pythona (PIL).

3.7.2 SDO_GEOM.SDO_BUFFER

Tworzy wokół obiektu strefę buforową o zadanych parametrach (odległość oraz tolerancja). Pierwszym parametrem jest odległość czyli rozmiar zadanego buforu. Bufor może mieć wartość ujemną, tak aby utworzony obiekt w większej skali óbcinany był z niepotrzebnych kawałków. Drugim parametrem jest tolerancja. Tolerancja służyć ma

do korygowania niedoskonałości zarówno w posiadanych danych, jak i również utworzonych zapytań z nim związanych. Stosujemy dwa bufor, tak aby jeden z nich korygował niedoskonałości wcześniej zastosowanego.

3.7.3 SDO_GEOM.SDO_CONVEXHULL

Argumentem jest obiekt SDO_GEOMETRY, metoda zwraca obiekt SDO_GEOMETRY będący wypukłą otoczką (convex hull) obiektu. Parametrem drugim jest tolerancja (opisana punkt wyżej).

3.7.4 MDSYS.SDO_GEOMETRY

Tworzy strukturę geometryczną o zadanych parametrach. Dokładny opis metody jest mocno zawiły, przyjmuje ona jako argumenty punkty mające stanowić polygon jak i również typ polygonu do utworzenia (prostokąt, romb, wielobok nieregularny).

3.7.5 SDO_GEOM.SDO_ELEM_INFO_ARRAY

Informuje o formacie danych podawanych przy tworzeniu polygonu (pierwszym argumentem jest numer początkowy z mapy punktów, drugi argument definiuje typ podawanych elementów (np. relacje jak w wypukłym polygonie)).

3.7.6 SDO_ORDINATE_ARRAY

Formatuje zadane punkty (oddzielone kolejno przecinkami) do formatu akceptowanego przez powyższe funkcje.

3.8 Konkretnie zadania wizualizujące

3.8.1 Wizualizacja izoterm

Do wizualizacji izoterm wykorzystaliśmy zapytania GeoDjango pozwalające na wybranie Resortów w określonej odległości od danego Resortu początkowego. Znajduje się ono pod adresem iso.


```
points_data = Resorts.objects.filter(
    position__dwithin=(self.position, distance_km),
    measuresresorts__measures__min_temp__lt=temperature
).unionagg().coords
```

Następnie po przekonwertowaniu danych do odpowiedniego formatu korzystamy z nich przy generowaniu zapytania SQL.

```
SELECT SDO_UTIL.TO_WKTGEOMETRY(  
  SDO_GEOM.SDO_BUFFER(  
    SDO_GEOM.SDO_BUFFER(  
      SDO_GEOM.SDO_CONVEXHULL(  
        MDSYS.SDO_GEOMETRY(  
          2003,  
          4326,  
          NULL,  
          SDO_ELEM_INFO_ARRAY(1, 2003, 1),  
          SDO_ORDINATE_ARRAY(%s)),  
        50),  
      100, 50, 'unit=m'),  
      -20, 50, 'unit=m')  
    ) FROM WORLD_WORLDBORDERS;" % points_str
```

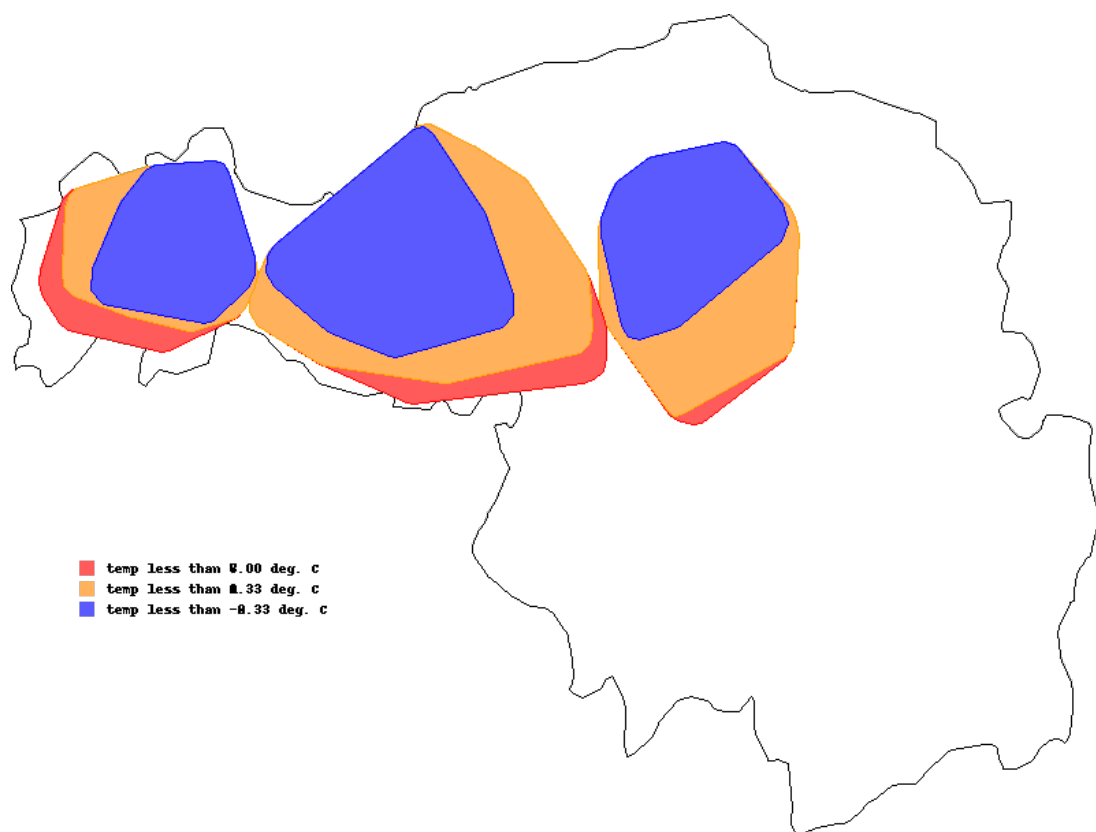
Zaczynając od wewnątrz, metoda `SDO_GEOMETRY` o parametrach 2003 (polygon wypukły), 4326 (system koordynacji, do dostosowywania polygonu do reszty danych GIS, pierwszy bufor o tolerancji 50m oraz dystansie 100m wokół punktów, drugi bufor ucina (buforuje 'do wewnątrz') o 20m. Całość zamieniana jest do formatu well-known text.

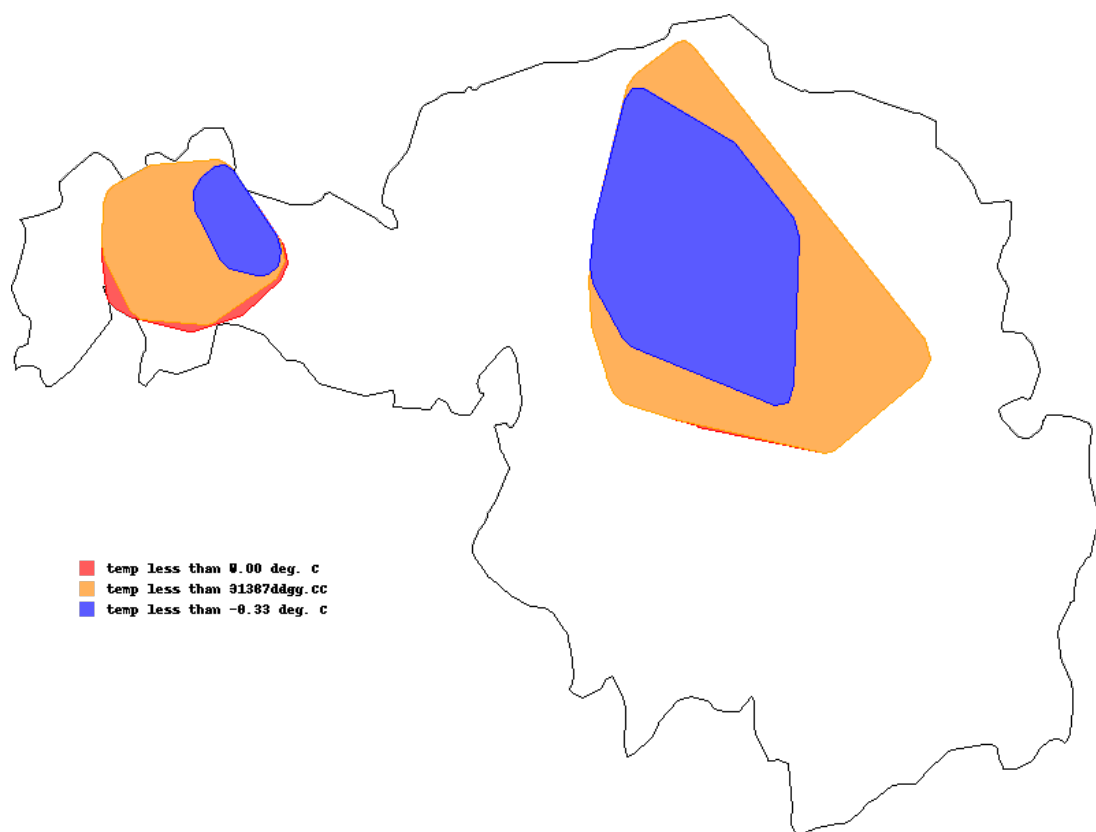
Zwracane dane to (w przypadku pomyślnego wyszukania odpowiednich danych resortów, POLYGON w formacie WKT (well-known text). Następnie polygon przetwarzany jest przez odpowiednie metody w PIL (python imaging library) i wraz z danymi GIS danego kraju tworzony jest obraz przedstawiający izotermę następującej postaci:

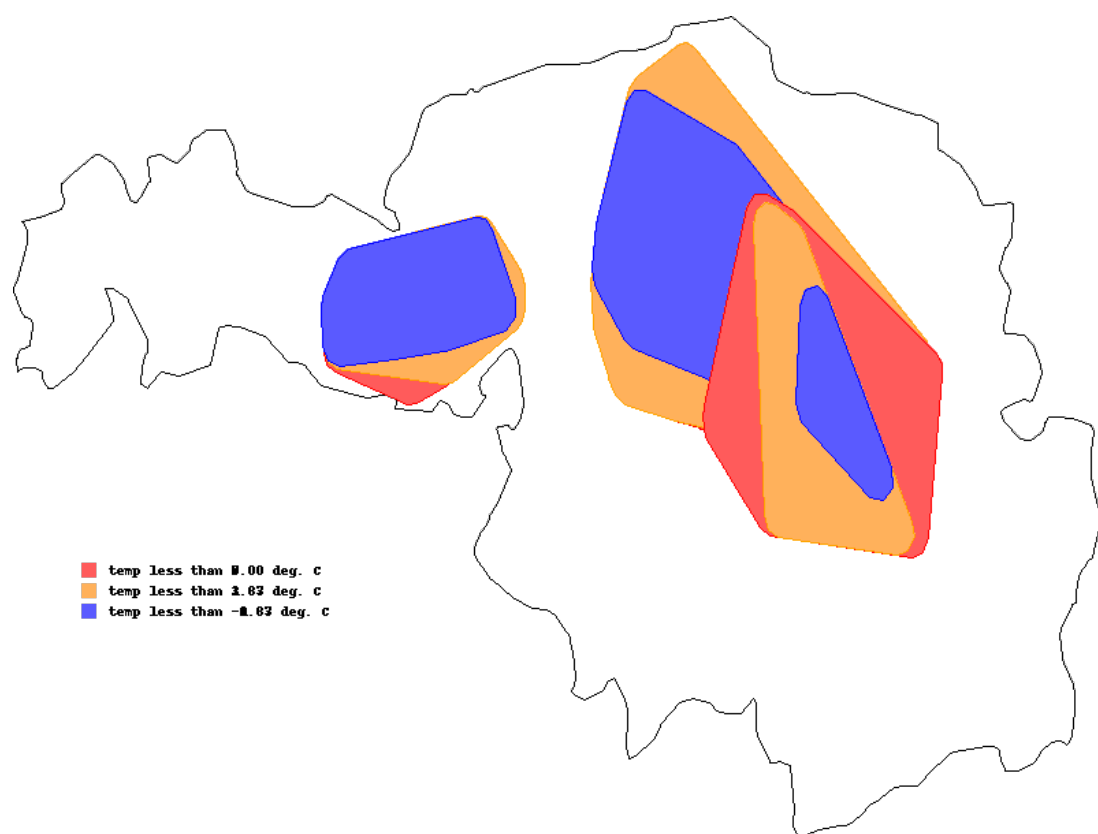


4 Wyniki wizualizacji isoterm.

W celu dopracowania systemu wizualizacji zaczęliśmy grupować zestawy ośrodków w zadanej odległości od głównego o zbliżonych pomiarach temperatur. Wprowadziliśmy różną kolorystykę w celu usprawnienia odczytu wykresów, jak również wprowadziliśmy opis legendy (która również generowana jest optymalnie do dostępnych wskazań temperatury w zadanym dniu. Mimo nie do końca kompletnych i sprawnych danych udało nam się osiągnąć zadowalające wyniki:







5 Crawler

Crawler jest napisany w języku Ruby i służy do pobierania danych ze strony <http://www.snow-forecast.com>. Docelowo będzie to prosty skrypt oparty o metodologię *Extract-Transform-Load*.

5.1 Extract

- uruchamiamy skrypt z parametrem adresu strony (w zasadzie chodzi o wybrany szczyt)
- skrypt analizuje stronę za pomocą parsera HTML+XML Nokogiri
- dane zapisywane są w prostej postaci w tablicy
- skrypt znajduje link do danych z poprzedniego okresu, odwiedza go i powtarza proces

Dane zapisywane są przez

```
file = File.open(filename, "w")
file.write(Marshal.dump(data))
```

Aby je odczytać wystarczy

```
data = Marshal.load(File.read(filename))
```

6 Raport z prac

6.1 Crawler

- przygotowanie skryptu mającego na celu pobieranie danych pogodowych z internetu, wybór najważniejszych danych oraz sposobu ich uzyskania
- implementacja części *Extract* wydobywającej dane ze stron internetowych
- implementacja części *Transform* przerabiającej surowe dane na potrzeby aplikacji
- implementacja części *Load* tworzącej SQL-e i wykonująca je w kontekście bazy.

6.2 Import danych

- utworzenie odpowiednich tabel do przetrzymywania danych, utworzenie relacji między tabelami
- zmapowanie tabel w modelach Django
- ustalenie formatu danych oraz ich konwersja do formatu odpowiadającego modelowi w bazie danych
- zaimportowanie danych do bazy danych

6.3 Analiza danych

- umożliwienie wyświetlania prognozowanych danych dla resortów, dla których istnieją pobrane dane (podpierając się GIS)
- listowanie resortów w zadanej odległości
- możliwość zacieśnienia przeszukiwanych/porównywanych resortów tylko i wyłącznie do określonego regionu (bazując na zadanej odległości)
- możliwość wydobywania danych GIS reprezentujących obszary spełniające konkretnie zadane parametry (np. izotermy)

6.4 Wizualizacja danych

- wizualizacja ośrodków za pomocą Google Maps API
- wizualizacja ośrodków znajdujących się w konkretnych odległościach od zadanych z pomocą Google Maps API
- generowanie wykresów na podstawie danych historycznych (np. temperatury z ostatniego tygodnia)
- wizualizacja izoterm na mapie Austrii, bazujących na dostępnych danych, o różnych poziomach przedziałów temperatur.
- implementacja cache'owania wygenerowanych wcześniej wizualizacji w celu oszczędności czasu.

6.5 Dodatkowe

- implementacja wyszukiwania ośrodków
- próba wykorzystania Google Maps API do prezentowania dokładniejszej odległości danego ośrodka od użytkownika (na podstawie jego aktualnej pozycji np. w preferencjach)
- implementacja systemu pobierającego preferencje wyszukiwania użytkownika, preferowanych danych a następnie
- wizualizacji izoterm o zadanych parametrach w przeglądarce internetowej.

7 Linki

Źródła (repozytorium Git) <http://github.com/michalbugno/projekt-oszbd/>

Projekt Django <http://www.djangoproject.com/>

Projekt GeoDjango <http://geodjango.org/>

API GoogleMaps <http://code.google.com/apis/maps/documentation/>

System kontroli wersji Git <http://git-scm.com/>

Python <http://www.python.org/>

Ruby <http://www.ruby-lang.org/>

Oracle Spatial http://download.oracle.com/docs/cd/B10501_01/appdev.920/a96630/toc.htm